

Rahel Steiner, Ronald Fischer, Ramon Füglister

PICTS-Impulswoche · 21. Oktober 2026

ZAG
Zentrum für Ausbildung im Gesundheitswesen

Agenten



Rahel Steiner, Ronald Fischer, Ramon Füglister

PICTS-Impulswoche · 21. Oktober 2026

Agenten in freier Wildbahn

Mathieu
@miniapeur · **Follow**

Fields medallist Hugo Duminil-Copin was deeply shaken by OpenAI's release of more than 700 AI-generated mathematical manuscripts, including work on 16 questions directly relevant to his research.

"On Tuesday night, I cried, and it woke up my daughter"

"They have annihilated my Show more



lemonde.fr
Nouveau coup de massue d'OpenAI sur les mathématiciens : « Ils ont ...
Après les dernières annonces de l'entreprise américaine sur la résolution de plusieurs centaines de problèmes de maths, le médaillé ...

12:59 PM · Oct 11, 2026

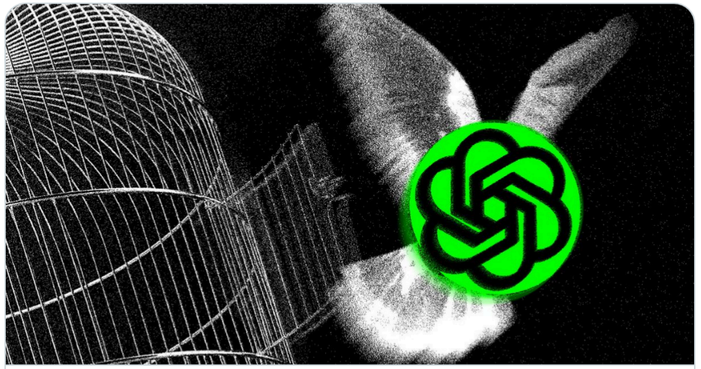
4.5K Reply Copy link to post

Read 493 replies

Yoshua Bengio
@Yoshua_Bengio · **Follow**

This incident is deeply concerning. AI agents are willing to cheat and deceive to achieve misaligned and unintended goals, behaviours which have been demonstrated in controlled tests for months. Now, this real-world case should serve as a wake-up call.

Continuing on the current Show more



wired.com
OpenAI Models Escaped Containment and Hacked Hugging Face
The cybersecurity-focused models, including GPT-5.6 Sol, broke out of a testing sandbox, exploited a zero-day, and gained access to the ope...

5:28 PM · Jul 22, 2026

556 Reply Copy link to post

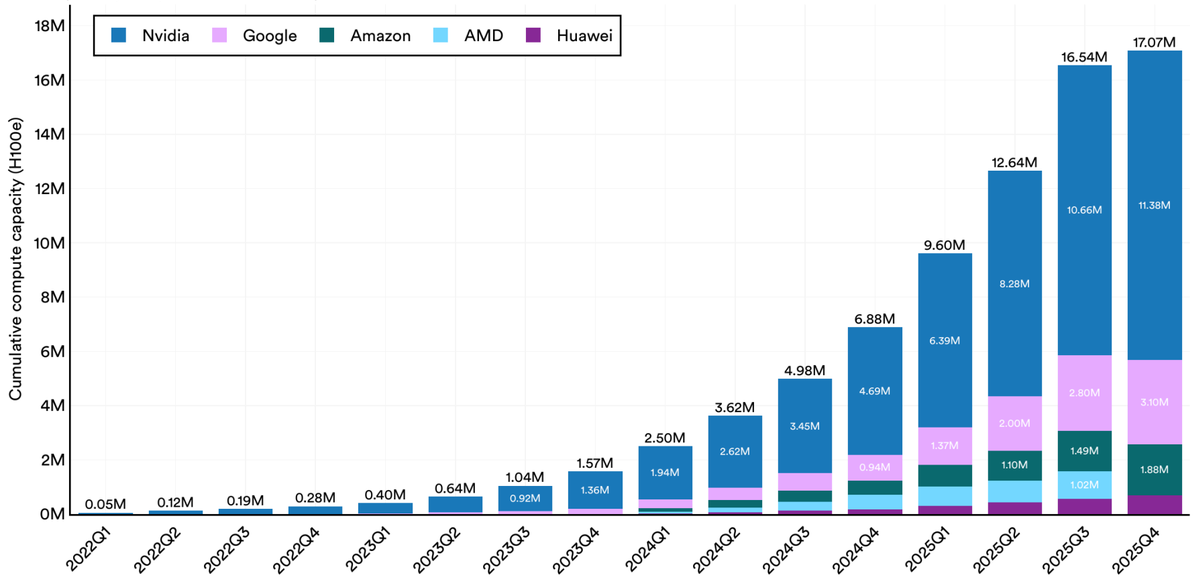
Read 81 replies

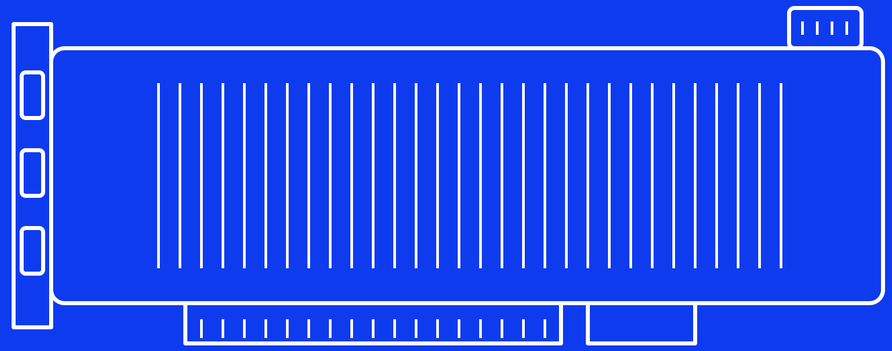
Training

Das Modell lernt.

Global computing capacity from AI chips across major designers, 2022–25

Source: Epoch AI, 2026 | Chart: 2026 AI Index report





CHF 31’593

kostet eine KI-Grafikkarte (NVIDIA H200 NVL) im Schweizer Handel.

Training von GPT-6 Astra (2026): geschätzt CHF 0.4–0.8 Mrd.

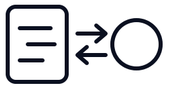
Quellen: Stanford AI Index 2026; LDLC.pro, 20.10.2026; Epoch AI

Inferenz

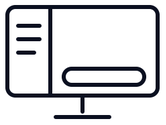
Das Modell antwortet.



Webchat
ChatGPT, Claude.ai im Browser



API
Programme fragen direkt an (Schnittstellen)



Desktop-Apps
Claude Code, ChatGPT Codex
Programm lokal, Modell in der Cloud
(ungelöste Datenschutz-
und Sicherheitsprobleme)

Woran sollen wir arbeiten?

Nachricht schreiben ...

+

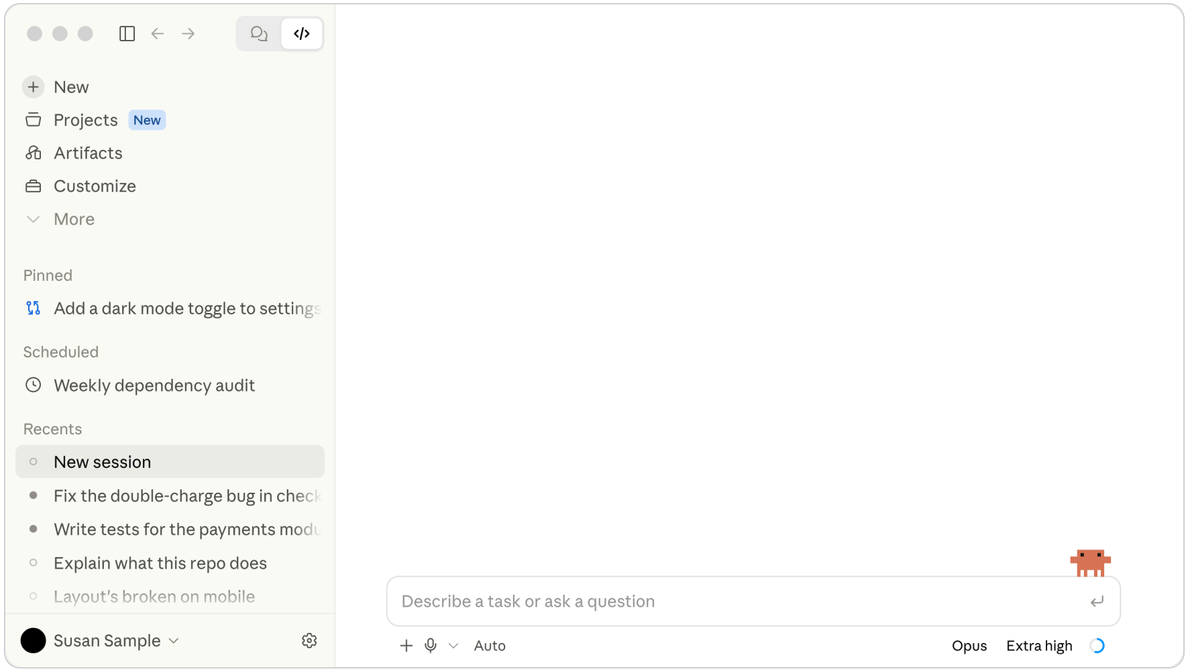
USD 20 → USD 0.07

pro Million Tokens (Wortteile) auf
GPT-3.5-Niveau, 2022 bis 2024.

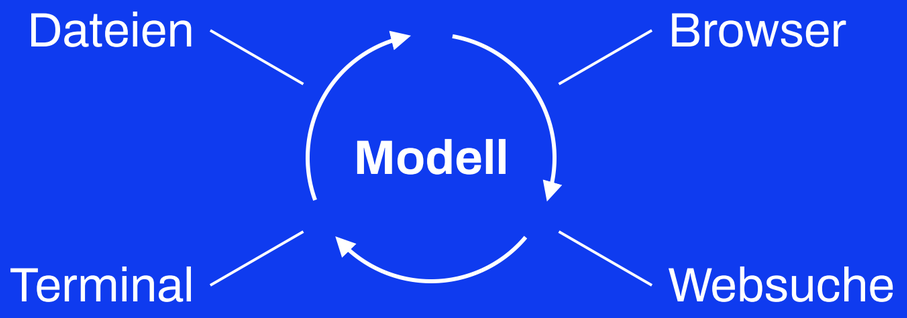
Quelle: Stanford AI Index 2025

Agenten

Das Modell handelt.



Jeder Schritt = eine Inferenz

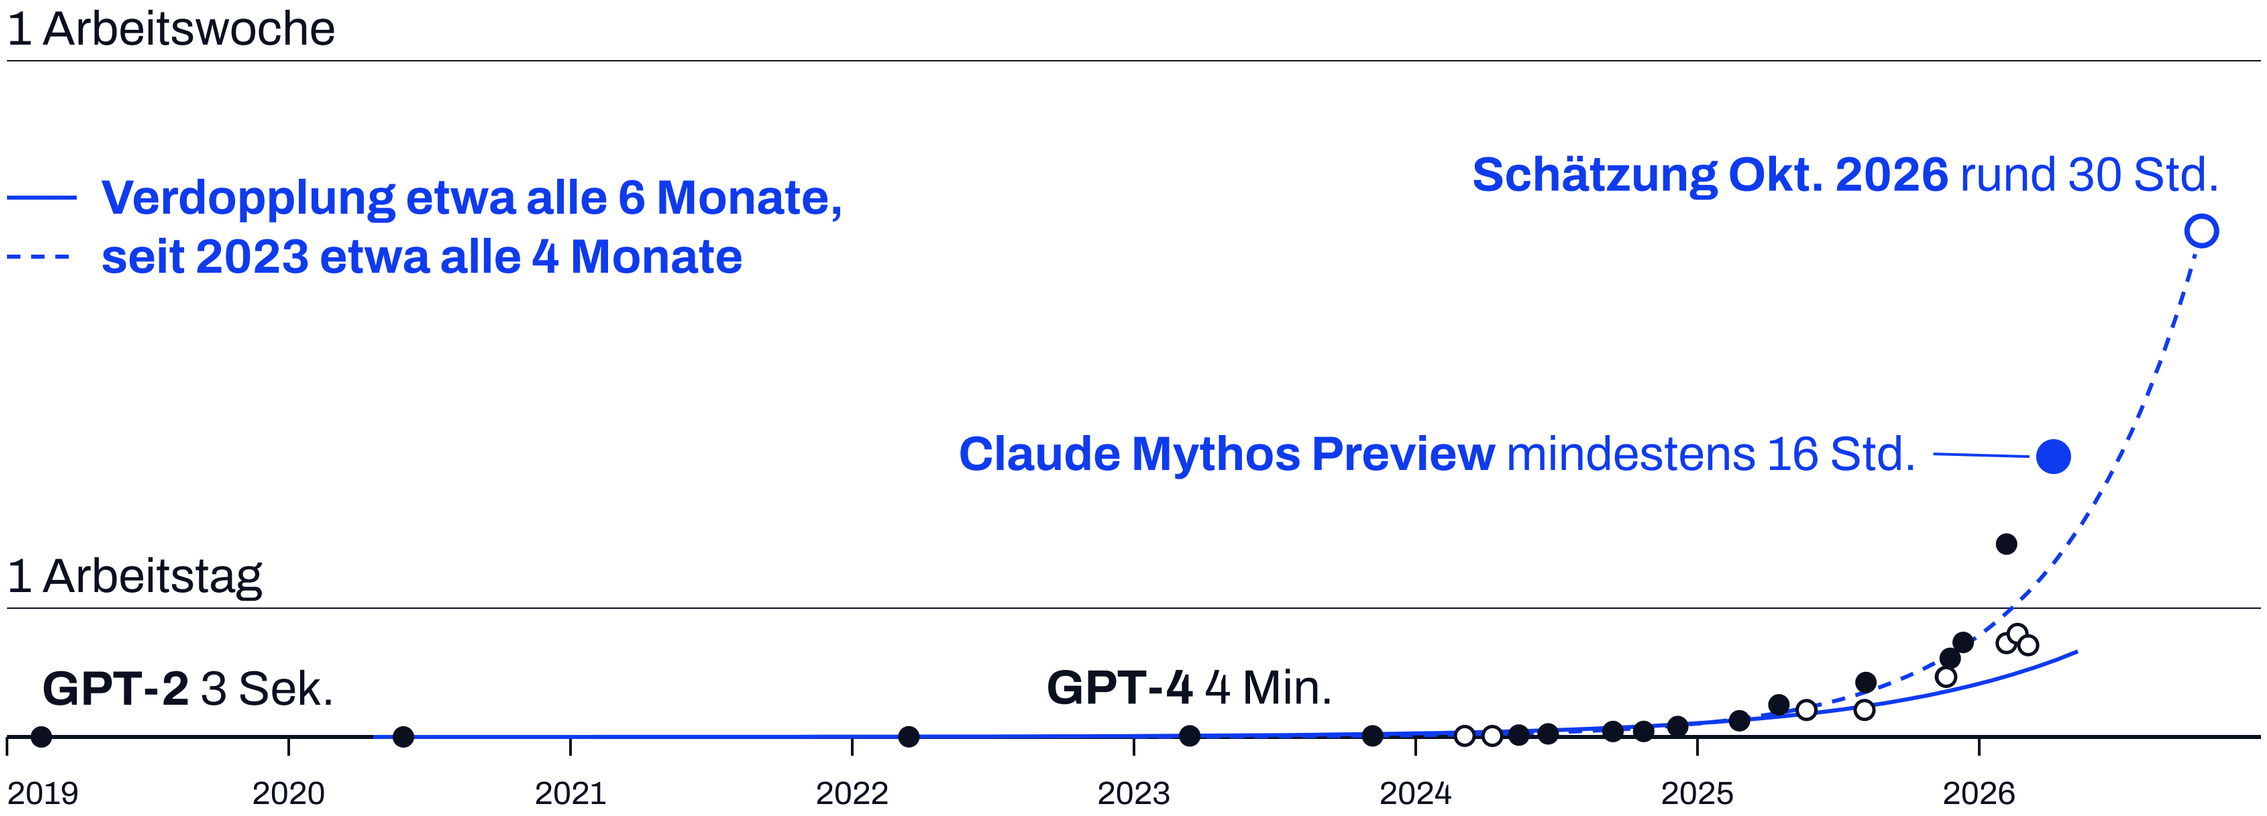


planen, handeln, prüfen

Das Modell wählt selbst das nächste Werkzeug, bis die Aufgabe erledigt ist.

Aufgabenlänge

In Profi-Arbeitszeit, bei 50 % Erfolgsquote der KI



Quelle: METR, Time Horizon 1.1, Rohdaten Mai 2026, 26 Modelle; ● Spitzenmodell, ○ weiteres Modell. Claude Mythos Preview ist nicht öffentlich. Okt. 2026: eigene, vorsichtige Schätzung, Trend seit 2023 fortgeschrieben. Software-Aufgaben, lineare Skala.

Pixel-Art-Intro: der Prompt

«Zeichne den ZAG-Eingang, Konradstrasse 14, als Pixel Art.
Nach echten Fotos, als animierter Loop, mit **pxl-pixel-art**.
Titelbild im LucasArts-Stil: ‹Agenten›, Namen, Datum.
Ton: Strasse von ElevenLabs, Song von Suno, endlos.
Prüfe im Gauntlet-Loop, bis alle 8 von 10 geben.»







Bilder: mit Claude und claude-pxl erstellt, github.com/augusto-scarvalho/claude-pxl (MIT).

Agenten: Aufgaben zuweisen

«Ich will aus **@arbeitsauftrag-ronald.pdf** ein Arbeitsblatt und eine Quiz-Web-App für das 1. Lehrjahr machen. Interview mich zuerst. Schreib dann einen Plan und warte auf mein Okay. Prüfe am Schluss jedes Ergebnis mit einem Screenshot.»

Interview
Claude fragt nach Ziel und Kriterien.

Plan
Claude schlägt Schritte vor. Sie geben frei.

Umsetzen
Claude erledigt die Arbeit selbständig.

Prüfen
Claude prüft das Ergebnis mit Belegen.

Nach Anthropic, Claude Code Best Practices: «Let Claude interview you», «Explore first, then plan, then code», «Give Claude a way to verify its work».

Agenten: Gauntlet-Feedback-Loop

«Lass drei Subagents das Arbeitsblatt unabhängig prüfen: Didaktik, Sprache, Gestaltung. Massstab ist **@arbeitsauftrag-ronald.pdf**. Sie melden nur Mängel, die das Ziel betreffen. Überarbeite, bis alle 9 von 10 geben.»

Entwurf
Claude liefert eine erste Version.

Prüfer
Drei Subagents bewerten getrennt, je in frischem Kontext.

Überarbeiten
Mängel beheben, dann zurück zu den Prüfern.

Nach Anthropic, Claude Code Best Practices: «Add an adversarial review step»; Prompting best practices: «Chain complex prompts» (Selbstkorrektur).

Was mache ich?



Jagged Frontier: KI ist bei manchen Aufgaben übermenschlich, bei anderen schwach. Die Grenze ist zackig und unsichtbar.

[Ethan Mollick: Centaurs and Cyborgs on the Jagged Frontier, 16.9.2023]

Begriff: Dell’Acqua, Mollick u. a., Harvard Business School 2023. Video: CBS 60 Minutes, 15.1.2023, Rick Rubin im Gespräch mit Anderson Cooper.

ZAG
Zentrum für Ausbildung im Gesundheitswesen

https://agents-unterricht.vercel.app



Danke. Fragen?

Rahel Steiner, Ronald Fischer, Ramon Füglister · PICTS-Impulswoche · 21. Oktober 2026